

# Langages Formels

Anne Gazon – L3 Info Rennes 1

2015 – 2016, S1

## 1 Monoïdes libres, langages

### 1.1 Monoïdes

La théorie des langages est née dans les années 60 de la volonté des linguistes de formaliser la notion de grammaire (des langages naturels). Parmi eux, Noam Chomsky a défini quatre types de grammaires associées à quatre types de langages (type 0, 1, 2 et 3). Dans ce cours, nous étudierons les langages algébriques (type 2) et rationnels (type 3).

**def 1.1** Quelques définitions :

1. Alphabet — Ensemble  $\Sigma$  fini non vide de symboles, appelés lettres.
2. Mot sur  $\Sigma$  — Suite finie de lettres. On définit sa longueur  $|u| = n$ .
3. Le mot vide est noté  $\epsilon$  ou  $1_\Sigma$ ,  $|1_\Sigma| = 0$ .
4.  $\Sigma^*$  désigne l'ensemble de tous les mots sur  $\Sigma$ .
5. La loi de composition interne sur  $\Sigma^*$  notée  $\cdot$  est la concaténation, qui est associative et admet  $1_\Sigma$  comme élément neutre.
6. Et ça, c'est un monoïde.

**def 1.2** Un monoïde est dit libre lorsque la décomposition d'un élément quelconque en "éléments de base" suivant sa loi de composition, est unique.  $\Sigma^*$  est alors le monoïde libre engendré par  $\Sigma$ .

*Remarque 1* — On voit immédiatement que deux mots sont égaux si et seulement si ils sont de même longueur, et ont leur lettres égales deux à deux. Cette propriété caractérise les monoïdes libres.

**def 1.3**  $v$  est un facteur de  $u \Leftrightarrow \exists \alpha, \beta \in \Sigma^*, u = \alpha v \beta$ ;  $c$  est un facteur droit (resp. gauche) si  $\beta = 1_\Sigma$  (resp. si  $\alpha = 1_\Sigma$ ). C'est un facteur propre si  $v \neq u$  et  $v \neq 1_\Sigma$ .

**def 1.4** Pour  $x \in \Sigma$ ,  $|\cdot|_x$  est le nombre d'occurrences de  $x$  dans un mot; on définit de même le nombre d'occurrences d'un mot dans un autre.

### 1.2 Langages

Un langage est un ensemble quelconque de mots ( $L \subseteq \Sigma^*$ ,  $L \in \mathcal{P}(\Sigma^*)$ ). L'union, l'intersection et le complémentaire sont définis intuitivement sur les langages.

**def 1.5** Les autres opérations usuelles sont le produit  $L \cdot M = \{uv | u \in L \text{ et } v \in M\}$ , l'étoile de Kleene  $L^* = \bigcup_{n \geq 0} L^n$  et l'étoile propre  $L^+ = L^* \setminus L^0$ .

## 2 Grammaires algébriques

**def 2.1** Une grammaire est un quadruplet  $G = (\Sigma, V, S, P)$  où  $\Sigma$  est l'alphabet terminal,  $V$  disjoint de  $\Sigma$  l'alphabet des non-terminaux,  $S \in V$  l'axiome de  $G$  et  $P \subseteq V \times (X \cup V)^*$  l'ensemble des règles de production.

EXEMPLE

$G_1 = (\Sigma, V, S, P)$  avec  $\Sigma = \{a, b\}$ ,  $V = \{S, T\}$  et les règles de production  $P \rightarrow aSb + aT$ ,  
 $T \rightarrow b$ .

**def 2.2** Une grammaire est dite linéaire (resp. à droite et à gauche) si  $P \subset V \times (\Sigma^* \times V \times \Sigma^* \cup \Sigma^*)$  (resp.  $\Sigma^* \times V$  and so on).

EXEMPLE

$G_1$  est linéaire.

La dérivation consiste à engendrer un mot à partir d'un autre en suivant une règle de production. Elle est notée  $\rightarrow$ , sa fermeture réflexive  $\rightarrow^*$  et une dérivation à l'ordre  $n$ ,  $\rightarrow^n$ .

**def 2.3** Le langage engendré par une grammaire est  $L(G) = \{f \in \Sigma^* \mid S \rightarrow^* f\}$  (le langage élargi accepte aussi  $V^*$ ). Réciproquement, un langage est dit algébrique s'il existe une grammaire  $G$  telle que  $L = L(G)$ .

*Remarque 1* — Pour prouver qu'une grammaire engendre un langage, on doit donc vérifier deux inclusions.

EXEMPLE

$$L(G_1) = \{a^n b^n \mid n \geq 1\}$$

La famille des langages algébriques sur un alphabet  $\Sigma$  est notée  $Alg(\Sigma^*)$ .

**lem 2.1** Lemme fondamental : soit  $G$  une grammaire,  $f \in (\Sigma \cup V)^*$ . Si  $f$  se factorise en  $f_0 S_1 f_1 \dots S_k f_k$  où  $f_i \in \Sigma^*$  et  $S_i \in V$ , alors pour tout  $g \in (\Sigma \cup V)^*$ ,

$$f \rightarrow^* g \Leftrightarrow g = f_0 h_1 f_1 \dots h_k f_k \text{ et } \forall i S_i \rightarrow^* h_i$$

Plus précisément,  $f \rightarrow^n g$  si idem et  $\forall i S_i \rightarrow^{n_i} h_i$  avec  $\sum n_i = n$ .

**prop 2.2** Principe de récurrence : soit  $S \subset \mathbb{N}$  telle que  $0 \in S$  et  $\forall n, n \in S \Rightarrow n+1 \in S$ . Alors  $S = \mathbb{N}$ .

*Remarque 2* — En appliquant ce principe à une propriété  $\mathcal{P}(n)$  pour  $n$  entier, on peut démontrer des trucs. Il existe aussi la version dite forte de la récurrence.

**def 2.4**  $A$  est un arbre de dérivation pour une grammaire  $G$  si les étiquettes de  $A$  sont dans  $\Sigma \cup V \cup \{\epsilon\}$ , les  $\epsilon$  n'ont pas de frères et les nœuds  $E$  de fils  $e_1, \dots, e_n$  sont tels que  $E \rightarrow e_1, \dots, e_n$  est une règle de production de  $G$ .

*Remarque 3* — Les nœuds internes sont donc nécessairement étiquetés dans  $V$ .

**def 2.5** Une grammaire est ambiguë si elle génère des mots qui possèdent plusieurs arbres de dérivation distincts.

On peut choisir de dériver à gauche ou à droite pour gérer l'ambiguïté.